

王芳

籍贯：河南周口 | 电话：19198028103 | 邮箱：qkds8848@126.com



教育背景

郑州大学 (211、双一流)	网络与信息安全	2024.09 - 2027.06
长沙理工大学 (本科)	计算机科学与技术	2020.09 - 2024.06

实习经历

上海寻序人工智能科技有限公司 AI agent开发	2026.03 - 2026.05
---------------------------	-------------------

项目：X-Code (VSCode AI 编码智能体)

技术栈：LLM Tool Calling, ReAct/Plan-and-Solve Agent Workflow, Prompt Engineering, Vector DB (Qdrant), Code Embedding, Tree-sitter (AST 解析)

- **项目描述**：基于 VS Code 的 AI 编码 Agent：多模型对接、XML 标签工具调用、MCP 工具生态、可选代码向量索引 (Qdrant) 与任务级成本可观测。我负责 **Agent 核心能力与基础架构建设**，重点攻克复杂代码上下文 RAG 检索策略、以及长会话状态管理等关键难题。
- **核心工作**：
 - **设计并实现 McpHub**：基于 MCP 官方 SDK 统一接入 stdio / SSE / streamable-http，全局配置与 .roo/mcp.json 项目级配置分层；文件监听 + 防抖实现配置热更新，stdio 支持 watchPaths 触发热重启。
 - **XML 标签式工具协议**：流式解析助手输出中的 <工具> / <参数>，驱动内置工具与 MCP 工具执行闭环。
 - **高精度 Code-RAG 检索链路设计**：利用 Qdrant 向量库实现代码切片的 embedding，codebase_search tool 语义检索，结合 Tree-sitter 与 search_files 提供精准的完整函数上下文，大幅提升了逻辑 Bug 定位与调优的准确率减少长上下文噪音，。
 - **AI 任务性能调优与可观测闭环**：滑动窗口、上下文压缩 (condense) 等节省 token；上下文长度估算使用 Worker 线程池 + tiktoken，减轻扩展宿主阻塞；计费与展示与 API usage (及缓存读写统计) 对齐。

项目：Android NDK 原生 C++ 库

技术栈：C++、OpenCV、量化模型输出后处理、车载/图像实时 pipeline

- **项目描述**：车载感知相关 Android Native 模块，面向车端场景，C++ 端接收 Java 端的车端摄像头图像数据，用 **Qualcomm QNN (HTP)** 跑多个模型，再配合 **OpenCV** 做图像与特征处理，完成模型推理与后处理，输出工况与辐射等信号。
- **核心工作**：
 - **辐射模型后处理**：基于多 ROI (顶/中/底) 与掩膜统计构造 **37 维** 输入特征并完成归一化；对量化输出做反量化，设计 **滑动均值 / 突变抑制** 与 **照度门控** (低照度退化路径)，稳定端侧输出。
 - **大幅降低系统 CPU 开销与延迟**：主导重构 NDK 图像传输架构，以 "C++ 按需轮询" 机制替代低效的 "Java 推送" 系统，成功将相机预览帧率与 AI 算法推理帧率解耦，提升系统流畅度。
 - **推动太阳辐射 AI 模型的升级与落地**。重构 C++ 端数据预处理流水线，适配扩展至 41 维的输入张量，确保多维度硬件数据的正确归一化处理，保障车载大灯和雨刮器控制算法的实时推理。
 - **维护高鲁棒性 C++ 数据流**：运用 OpenCV 进行底层图像预处理，优化内存管理，确保多维张量数据在进入高通神经网络 (QNN) 引擎前完成高精度的特征归一化。

项目经历

仿12306售票系统

2024.12 - 2025.04

技术栈：Spring Boot + MyBatis + Redis + RocketMQ + MySQL

- **项目描述**：针对节假日火车票抢购场景设计的高并发售票系统，实现了车次查询、座位动态生成、订单处理及支付功能。重点解决了高并发下的**超卖与服务雪崩**问题。
- **核心工作**：
 - 基于 **Redis + Lua 脚本** 实现了原子性的**高并发库存扣减**机制，解决超卖问题。在分布式场景下，引入 **Redisson** 实现分布式锁（看门狗机制）保障跨服务的数据一致性，并结合 **Cache Aside Pattern** 策略维护数据库与缓存的一致性。
 - 针对抢票瞬间的流量洪峰，设计了基于 **RocketMQ** 的**异步削峰填谷**方案，保护下游 MySQL 数据库不被击穿，同时保证了消息的**最终一致性**。引入 **Sentinel** 实现核心业务的**流量控制与熔断降级**。针对“查票/下单”接口配置 **QPS 限流与热点参数限流**，有效抵御突发流量与爬虫攻击；
 - 基于 **JWT + Spring Security** 定制鉴权过滤器，实现了支持微信 OpenID 的无状态登录，并设计 RBAC 模型精确控制管理员与普通用户的接口访问权限。

专业技能

- **AI 后端工程**：具备 Java/Python 双栈 AI 工程落地能力。扎实的 Java/JUC 并发编程与 JVM 调优经验；熟练使用 Spring Boot，并掌握 **LangChain4j** 框架的集成；掌握基于 **RocketMQ /Kafka** 实现高并发请求削峰、异步结果回调及基于 **Redis** 实现多轮对话的 Memory 会话管理。
- **AI 智能体与应用编排**：精通大模型应用开发全流程，熟练使用 **Dify / Coze** 等 AI 编排平台。深入掌握 **LangChain** 框架，能够基于 **ReAct** 范式开发具备 Function Calling 能力的复杂 Agent 系统；精通 **Prompt Engineering**（CoT 思维链、Few-Shot），具备模型输出格式化、防越狱（Guardrails）及 Token 成本控制的实战经验。
- **RAG 系统与数据生态**：深入理解 **RAG（检索增强生成）** 全链路优化架构。熟练使用主流向量数据库；掌握复杂文档解析与长文本切分（Chunking）策略；精通 **Hybrid Search（混合检索）**、Query Rewrite（查询重写）及基于 BGE 等模型的 **Reranking（重排）** 技术，能有效解决长上下文场景中的召回率低与大模型幻觉问题
- **模型部署与微调引擎**：掌握 Python 语言与 PyTorch 框架，熟悉 Transformer 架构底层机制。熟练使用 **Ollama** 等框架进行开源大模型的本地私有化部署与推理加速；熟悉大模型微调全流程，掌握 **SFT（指令微调）** 与 **LoRA** 轻量化微调技术；了解 RLHF/DPO 对齐策略。

获奖荣誉

基于微信小程序的旅游系统软件著作权证书、第十五届中国大学生计算机设计大赛 省级二等奖、第十三届中国大学生服务外包创新创业大赛 省级三等奖、第十七届长沙理工大学 ACM 程序设计竞赛 校级二等奖、英语水平：CET-6 (具备良好的英文文档阅读能力)